

文章编号: 1007-7294(2021)03-0299-12

基于小波滤波和LSTM神经网络的 船舶运动极短期预报研究

刘长德¹, 顾宇翔², 张进丰¹

(1. 中国船舶科学研究中心, 江苏 无锡 214082; 2. 中船重工奥蓝托无锡软件技术有限公司, 江苏 无锡 214082)

摘要: 为了提高船舶运动极短期预报精度及预报时间长度, 本文采用小波多分辨率分析方法, 将含有噪声的船舶运动信号进行了多尺度小波变换, 通过采用阈值函数法对各尺度下细节信号的小波系数进行处理, 对小波分解层数、小波基函数、阈值处理方法进行了深入研究, 并通过模型试验数据对滤波效果进行了验证分析, 实现了船舶运动信号的小波滤波。进一步针对船舶运动的非线性特性, 基于深度神经网络的非线性映射能力, 建立了基于LSTM网络的多步直接映射船舶运动极短期预报模型, 并采用滤波后的船舶运动数据进行了不同工况下的预报分析。结果表明, 不同时间长度的预报与试验结果幅值和相位吻合较好, 验证了所建立的极短期预报模型的可行性。

关键词: 小波滤波; LSTM神经网络; 船舶运动极短期预报

中图分类号: U661.3 文献标识码: A doi: 10.3969/j.issn.1007-7294.2021.03.005

Extreme short-term prediction of ship motions based on wavelet filter and LSTM neural network

LIU Chang-de¹, GU Yu-xiang², ZHANG Jin-feng¹

(1. China Ship Scientific Research Center, Wuxi 214082, China;

2. Wuxi Orient Software Technology Co. Ltd., Wuxi 214082, China)

Abstract: In this paper, the wavelet analysis method is applied in the de-noising of test data in order to improve the prediction precision of ship motions. The test data of ship motions are decomposed by the multi-resolution theory. The filtering performance is validated by the test data of ship motions. On the basis of analytical results of the transforming characteristics of noise signal, the reasonable level of wavelet decomposition, wavelet basis function and threshold de-noising method are confirmed. Meanwhile, the extreme short time prediction model of ship motions is proposed based on Long Short Term Memory (LSTM) in order to improve prediction accuracy. The test results show that the prediction model has excellent performance. The most important outcome of the investigation is that the motion amplitude and phase are very well represented for different prediction interval lengths.

Key words: wave filter; LSTM neural network; ship motion prediction

0 引言

船舶在海上航行过程中, 由于受到风、浪、流等环境因素的干扰, 运动具有很强的随机性和非线性

收稿日期: 2020-09-03

基金项目: 工信部高技术船舶科研项目(工信部装函[2019]357)

作者简介: 刘长德(1982-), 男, 博士, 高级工程师, 通讯作者, E-mail: changde001@126.com;

顾宇翔(1993-), 男, 工程师。

性,尤其在恶劣的海况条件下,船舶的航行和海上作业会有很大的安全隐患。如果能提前预报未来时刻的运动状态,获得未来船舶运动的暂息期,对于辅助船舶的特定作业具有重要指导意义。

目前,国内外对船舶运动极短期预报的研究一般采用离线滤波方法,利用去除高频噪声后的数据进行预报结果的分析。对于船舶运动实测数据,所采集的数据不可避免地存在高频噪声,从而造成信噪比严重降低,文献[1]中以DDG-51驱逐舰为例离线分析了测量噪声对船舶运动极短期预报精度的影响,尤其是在运动峰值处会导致较大的预报误差,因此进行极短期预报时,必须对信号进行滤波处理。传统的滤波方法是将信号进行傅里叶变换,去除掉高频噪声,保留有用信号,通过逆变换得到真实信号。该方法虽然能去掉噪声,但易产生高频失真,而小波变换克服了傅里叶变换中时域的瞬间变化在频域不能反映出来的缺陷,其在低频部分具有较高的频率分辨率和较低的时间分辨率,在高频部分具有较高的时间分辨率和较低的频率分辨率,这正符合低频信号变化缓慢,而高频信号变化迅速的特点^[2]。在大尺度下,可以将信号的低频信息全局表现出来,在小尺度下,可以将高频局部特性表现出来,其优点在惯性导航系统信号分析中得到了充分体现^[3],这种特性使小波变换为船舶运动信号实时滤波提供了理论基础。

国内外对船舶运动极短期预报都非常重视并展开了许多研究,文献[4]对国内外研究现状进行了归纳总结,其中利用时间序列分析法对船舶运动姿态进行极短期预报越来越受到重视,早期的船舶运动极短期预报假设船舶在海浪中的运动姿态为一平稳的窄带随机过程,采用AR模型^[5]或ARMA模型^[6-8]实现了船舶运动姿态的实时预报。由于船舶运动具有较强非线性、非平稳甚至混沌特性,使得随着预报时间的增加,其预报精度下降明显,且运动相位误差变大,文献[9]针对船舶运动姿态在随机海浪作用下的非线性特性,利用Volterra级数的非线性表征能力,给出了船舶运动姿态时间序列的二阶Volterra自适应预测模型。随着机器学习及各种算法的提出,本世纪初,国内外学者应用人工神经网络对船舶运动极短期预报展开了研究,Khan等^[10]建立了BP神经网络和遗传算法相结合的方法,并与ARMA预报模型进行了比较分析,验证了神经网络非线性建模优点;Khan等^[11]结合神经网络、模糊逻辑与数据融合技术实现了船舶运动极短期预报的工程应用;文献[12]结合混沌相空间重构理论和RBF神经网络对极短期预报中建模数据、输入变量和收敛速度等进行了系统分析,为极短期预报工程化提供了理论基础。随着计算能力的提升,深度神经网络开始出现在时间序列预报中,得益于深度学习算法和硬件技术的突破,深度神经网络在相关领域攻克了许多难题,涌现出了许多基于机器学习算法的非线性时间序列预报模型^[13-15],其中LSTM神经网络有效解决了深度网络梯度爆炸、消失问题。

综上所述,本文针对船舶运动非线性特性和测量噪声对极短期预报精度的影响,在分辨率分析理论的基础上,建立了船舶运动小波分解、阈值处理和重构算法,并通过模型试验数据研究了不同小波基函数和分解尺度对滤波效果的影响,进一步结合LSTM神经网络,建立了多步直接映射船舶运动极短期预报方法,为船舶运动非线性逼近建模问题提供了有效的解决途径。

1 船舶运动信号小波滤波

1.1 小波变换

在小波变换分析中,对应的函数空间为 $L^2(R)$, $L^2(R)$ 为 R 上平方可积函数构成的空间。设函数 $f(t) \in L^2(R)$,其关于基小波的 $\psi_{a,b}(t)$ 连续小波变换的数学表达式为

$$W_{\psi} f(a,b) = \langle f, \psi_{a,b} \rangle = \int_{-\infty}^{\infty} f(t) \psi_{a,b}(t) dt \quad (1)$$

$$\psi_{a,b}(t) = |a|^{-\frac{1}{2}} \psi\left(\frac{t-b}{a}\right)$$

式中, $\bar{\psi}_{a,b}(t)$ 为基小波的共轭函数, $a,b \in R$,且 $a \neq 0$, a,b 分别为尺度因子和平移因子。

连续小波变换是冗余的,计算中不可能对所有尺度因子和平移参数小波变换,且实际的处理数据

都是离散的,因此本文采用离散小波变换。

令 $a = a_0^k$, $b = nb_0a_0^k$, $k, n \in Z$, $a_0 > 1$, $b_0 > 0$, 由母小波 $\psi(t)$ 伸缩和平移生成的函数族 $\{\psi_{a,b}(t)\}$ 的离散族 $\{\psi_{k,n}(t)\}$ 为

$$\psi_{k,n}(t) = a_0^{-k/2} \psi\left(\frac{t - nb_0a_0^k}{a_0^k}\right) = a_0^{-k/2} \psi(a_0^{-k}t - nb_0) \quad (2)$$

对 $f(t) \in L^2(R)$, 其离散小波变换为

$$W_\psi f(a,b) = a_0^{-k/2} \int_{-\infty}^{\infty} f(t) \bar{\psi}\left(\frac{t - nb_0a_0^k}{a_0^k}\right) dt, \quad k \in Z \quad (3)$$

通常取 $a_0=2$ 和 $b_0=1$, 则 $\psi_{k,n}(t) = 2^{-k/2} \psi(2^{-k}t - n)$, $k, n \in Z$ 。

为使得小波变换计算更加有效,所构造的小波函数一般具有正交性,即 $\psi_{k,n}(t)$ 、 $\psi_{k',n'}(t)$ 满足

$$\langle \psi_{k,n}(t), \psi_{k',n'}(t) \rangle = \int_{-\infty}^{\infty} \psi_{k,n}(t) \bar{\psi}_{k',n'}(t) dt = \delta_{kk',nn'} \quad (4)$$

则 $\psi_{jk}(t)$ 构成 $L^2(R)$ 上规范正交基,称为二进制正交小波基。

1.2 多分辨率分析与 Mallat 算法

Mallat 提出了多分辨率的概念,在多分辨率分析理论的基础上,提出了一种塔式快速小波分解算法和重构算法, Mallat 算法保证了分解后数据点数和分解前数据点数相同,是无冗余的小波变换。

对于一个多分辨分析中任意子空间 V_j , W_j 是 V_j 关于 V_{j+1} 的正交补空间,则 V_j 可分解为

$$V_j = V_{j-1} \oplus W_{j-1} = \cdots = V_M \oplus W_M \oplus W_{M+1} \oplus \cdots \oplus W_{j-1} \quad (M < j)$$

进一步可得 V_j 中的任意函数 $f_j(t)$ 都存在如下多分辨率分析表示:

$$f_j = f_{j-1} \oplus g_{j-1} = \cdots = f_M \oplus g_M \oplus g_{M+1} \oplus \cdots \oplus g_{j-1} \quad (M < j)$$

$$f_i(t) = \sum_k c_k^i \phi_{lk}(t) \in V_i, l = M, \cdots, j, g_i(t) = \sum_k d_k^i \psi_{lk}(t) \in W_i, l = M, \cdots, j-1。$$

式中, $f_i(t)$ 表示函数 $f_j(t)$ 的低频部分, $g_i(t)$ 表示 $f_j(t)$ 的高频部分; $\phi_{lk}(t) = 2^{\frac{1}{2}} \phi(2^l t - k)$, $l \in Z$ 为空间 V_j 的标准正交基, $\phi(t)$ 为多分辨率分析的尺度函数; $\psi_{lk}(t) = 2^{\frac{1}{2}} \psi(2^l t - k)$; $k \in Z$ 为 W_j 的 Riesz 基, $\psi(t)$ 为小波函数。

小波重构算法是基于尺度函数和小波函数的二尺度关系,通过小波逆变换,使得原函数能够根据不同尺度的分量完全恢复。考虑第 j 个分辨率下的分量和

$$f_{j+1}(t) = f_j(t) + g_j(t) = \sum_k c_k^j \phi_{jk}(t) + \sum_k d_k^j \psi_{jk}(t) \quad (5)$$

将二尺度方程代入式(5)可得

$$\sum_k c_k^j \phi_{jk}(t) + \sum_k d_k^j \psi_{jk}(t) = \sum_k c_k^j \sum_n h(n) \phi(2^{j+1}t - 2k - n) + \sum_n d_n^j \sum_k g(n) \phi(2^{j+1}t - 2k - n) \quad (6)$$


由 $f_{j+1}(t) = \sum_n c_n^{j+1} \phi(2^{j+1}t - k)$ 以及 $\{\phi_n^{j+1}: n \in Z\}$ 的线性无关性,可得到不同尺度下尺度函数和小波函数系数关系式为

$$c_l^{j+1} = \sum_k (c_k^j h(l - 2k) + d_k^j g(l - 2k)) \quad (7)$$

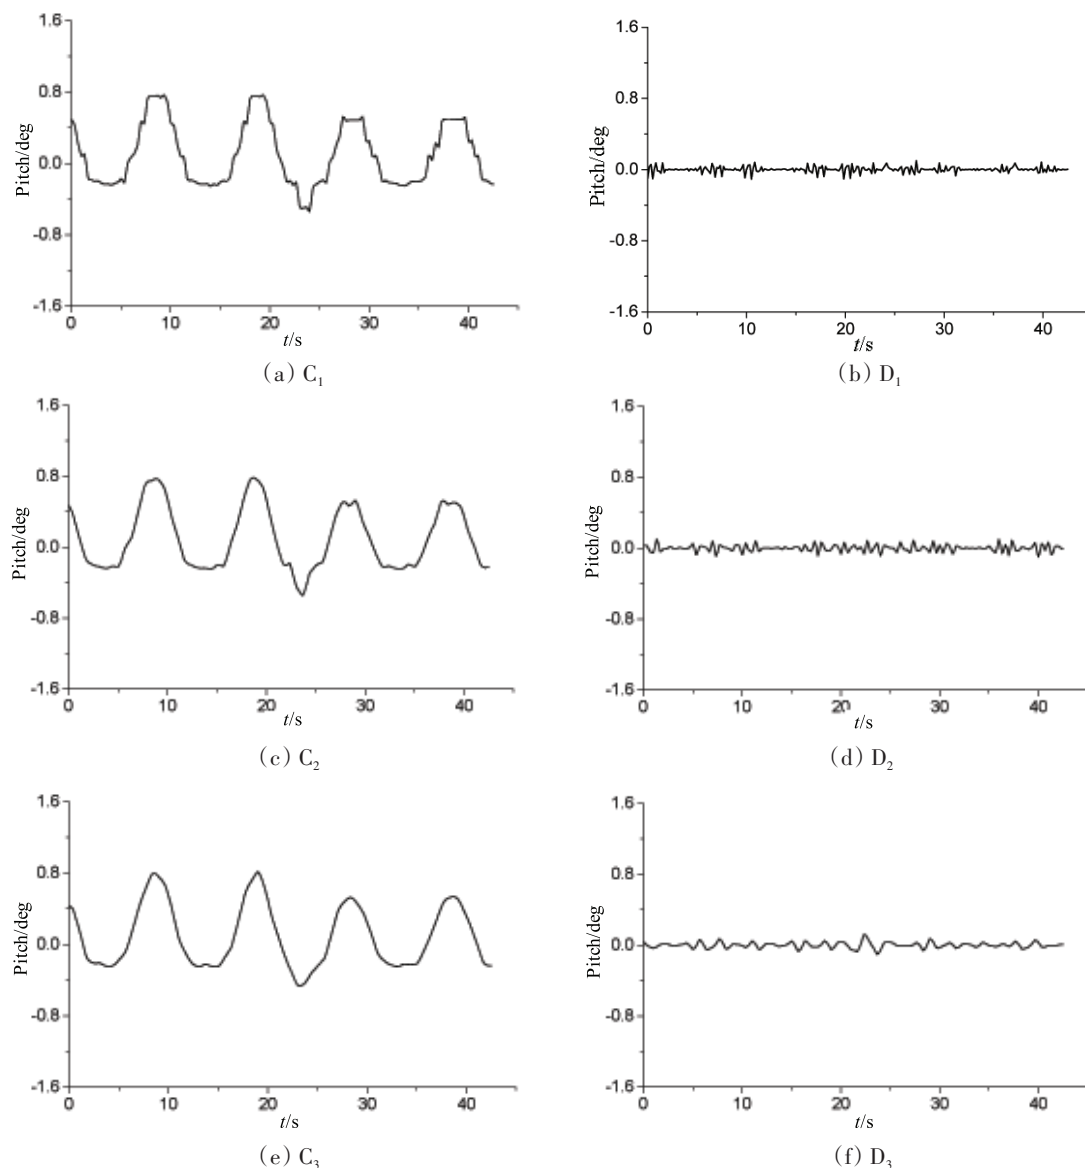
通过多分辨率分析方法,将含噪信号进行多尺度小波变换,从时域变换到小波域,在各尺度下提取信号的小波系数,去除含噪声的小波系数,然后用小波逆变换重构信号。

1.3 船舶运动小波滤波分析

采用船舶模型试验数据进行滤波效果验证分析,试验工况为艏斜浪 135°、航速 6 kn。为了更好地确定分解层数,采用周期图法对船舶横摇、纵摇运动信号时间历程进行功率谱分析。图 1 为测试工况下横摇、纵摇运动功率谱密度,由图 1 可知,当频率大于 1.5 Hz 时,其对应功率谱密度近似为零。

图1 运动功率谱密度(浪向 135° , $V=6$ kn)Fig.1 Power spectrum density of roll and pitch motion (wave direction: 135° , $V=6$ kn)

以艏斜浪 135° 纵摇运动(航速 $V=6$ kn)数据为例,采用db4小波对船舶运动信号进行5层分解,图2为对应5层分解后各层的低频逼近信号($C_1 \sim C_5$)和细节信号($D_1 \sim D_5$)。由图2可知,随着分解层数的增加,细节信号逐渐增强。







图2 纵摇运动db4小波5层分解(浪向135°, V=6 kn)

Fig.2 Decomposition of pitch motion with db4 wavelet (wave direction:135°, V=6 kn)

图3为各层逼近信号与细节信号的功率谱估计,由图3可以看出,随着分解层数的增加,细节信号功率谱密度峰值逐渐增大,且逐渐向低频方向移动。对于船舶运动时历信号,由于第1~4层细节信号主要表现为高频噪声,因此可采用硬阈值函数处理小波系数,阈值选取为0,即强制1~4层细节信号为0。






图3 纵摇运动db4小波分解信号功率谱(浪向135°,V=6 kn)

Fig.3 Power spectrum density of different decomposition levels (wave direction:135°,V=6 kn)

通过对细节信号的系数阈值处理后,分别对分解后的各层逼近信号进行重构,图4为采用硬阈值处理后重构信号与原始数据的对比,并与传统FFT滤波方法进行了比较。由图4可知,采用db4小波基函数可有效实现滤波,且在运动信号时历端点处,仍能逼真地反映原始信号,而传统FFT法虽然也可有效实现滤波,但在端点附近出现突变,使得滤波后端点附近的信号与真实信号偏差较大。由于在船舶运动极短期预报中需要当前时刻前一段历史数据作为样本建立模型,当前时刻前一段历史数据的真实性对所建立的预报模型的预报精度至关重要,因此小波滤波可有效提高船舶运动极短期预报模型的精度。




图4 纵摇运动滤波对比(浪向135°,V=12 kn)

Fig.4 Filtering comparison of pitch motion (wave direction: 135°,V=12 kn)

进一步采用上述相同的阈值处理方法,表1为采用dbN(N=2~8)系列、symN(N=2~8)系列小波基函数滤波效果的统计结果。由表1可知,dbN(N=3~8)、symN(N=3~8)系列小波对船舶运动信号滤波效果相当(FFT滤波均方差为0.005 0,信噪比为17.649 5)。

表1 不同小波基函数均方差统计结果

Tab.1 Mean square deviation with different wavelet bases

小波函数	均方差	信噪比	小波函数	均方差	信噪比
db2	0.007 4	16.061 0	sym2	0.007 4	16.061 0
db3	0.005 4	17.367 5	sym3	0.005 4	17.367 5
db4	0.005 1	17.606 7	sym4	0.005 1	17.604 0
db5	0.005 0	17.678 8	sym5	0.005 1	17.606 1
db6	0.005 0	17.708 7	sym6	0.004 9	17.750 7
db7	0.005 0	17.688 2	sym7	0.005 1	17.654 4
db8	0.004 9	17.744 3	sym8	0.004 9	17.740 9

2 LSTM神经网络预报原理

2.1 LSTM神经网络

长短期记忆(LSTM)神经网络是建立在RNN上的一种新型深度机器学习神经网络,通过在隐藏层各神经单元中增加记忆单元,使时间序列上的记忆信息可控,在输入、反馈与防止梯度爆炸之间建立了一个长时滞,该架构强制其在特殊记忆单元的内部状态保持持续误差流,从而使得梯度既不会爆炸也不会消失,其神经网络单元主要结构如图5所示。

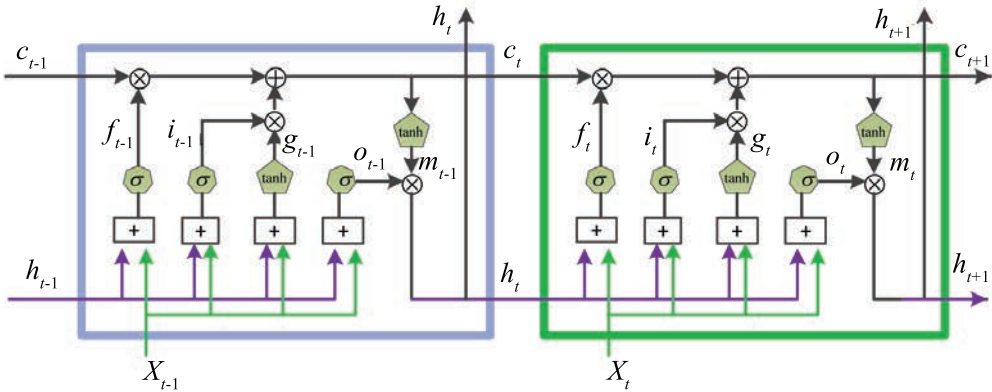


图5 LSTM神经单元结构图

Fig.5 LSTM unit structure

其每层神经元设计为具有多个门的结构,分别为输入门、遗忘门和输出门,具体计算步骤如下:

(1)输入门,用来计算哪些信息保存到状态单元中,包含两部分:一部分作为当前输入信息保存到细胞状态 i_t ,另一部分将当前输入产生的新信息添加到细胞状态 g_t ,从而产生新的记忆状态 c_t 。

$$i_t = \sigma(\tilde{i}_t) = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + b_i) \tag{8}$$

$$g_t = \sigma(\tilde{g}_t) = \sigma(W_{xg}x_t + W_{hg}h_{t-1} + b_g) \tag{9}$$

$$c_t = f_t c_{t-1} + i_t g_t \tag{10}$$

(2)遗忘门,用于计算信息的遗忘程度,通过sigmoid处理后为0或1的值,0表示全部忘记,1表示全部保留。

$$f_t = \sigma(\tilde{f}_t) = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + b_f) \tag{11}$$

(3)输出门,用于计算当前时刻信息被输出程度。

$$o_t = \sigma(\tilde{o}_t) = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + b_o), \quad m_t = \tanh(c_t), \quad h_t = o_t \cdot m_t \quad (12)$$

$$y_t = W_{yh}h_t + b_y \quad (13)$$

2.2 梯度计算

设 $\hat{y}_i(t)$ 、 $y_i(t)$ 为 t 时刻第 i 个单元的实际输出与目标输出, 定义损失函数 E :

$$E = \sum_{i=1}^T e_i(t), \quad e_i(t) = \|\hat{y}_i(t) - y_i(t)\|^2 \quad i = 1, 2, \dots, T \quad (14)$$

采用反向传播法, 求解各输入、输出节点的梯度, 初始化 $\partial E/\partial y_t$ 、 $\partial E/\partial c_{t+1}$ 、 $\partial E/\partial \tilde{o}_{t+1}$ 、 $\partial E/\partial \tilde{f}_{t+1}$ 、 $\partial E/\partial \tilde{i}_{t+1}$ 和 $\partial E/\partial \tilde{g}_{t+1}$, 则各节点梯度计算公式如下:

$$\begin{aligned} \frac{\partial E}{\partial h_t} &= \frac{\partial E}{\partial y_t} W_{yh}^T + \frac{\partial E}{\partial \tilde{o}_{t+1}} W_{ho}^T + \frac{\partial E}{\partial \tilde{f}_{t+1}} W_{hf}^T + \frac{\partial E}{\partial \tilde{i}_{t+1}} W_{hi}^T + \frac{\partial E}{\partial \tilde{g}_{t+1}} W_{hg}^T \\ \frac{\partial E}{\partial m_t} &= \frac{\partial E}{\partial h_t} \cdot o_t \\ \frac{\partial E}{\partial c_t} &= \frac{\partial E}{\partial m_t} \frac{dm_t}{dc_t} + \frac{\partial E}{\partial c_{t+1}} \cdot f_{t+1} \\ \frac{\partial E}{\partial g_t} &= \frac{\partial E}{\partial c_t} i_t, \quad \frac{\partial E}{\partial i_t} = \frac{\partial E}{\partial c_t} g_t, \quad \frac{\partial E}{\partial f_t} = \frac{\partial E}{\partial c_t} c_{t-1}, \quad \frac{\partial E}{\partial o_t} = \frac{\partial E}{\partial h_t} m_t \\ \frac{\partial E}{\partial \tilde{g}_t} &= \frac{\partial E}{\partial g_t} (1 - g_t^2), \quad \frac{\partial E}{\partial \tilde{i}_t} = \frac{\partial E}{\partial i_t} i_t (1 - i_t), \quad \frac{\partial E}{\partial \tilde{f}_t} = \frac{\partial E}{\partial f_t} f_t (1 - f_t), \quad \frac{\partial E}{\partial \tilde{o}_t} = \frac{\partial E}{\partial o_t} i_t (1 - o_t) \end{aligned} \quad (15)$$

各参数梯度计算公式如下:

$$\begin{aligned} \frac{\partial E}{\partial W_{xo}} &= x_t^T \frac{\partial E}{\partial \tilde{o}_t}, \quad \frac{\partial E}{\partial W_{xf}} = x_t^T \frac{\partial E}{\partial \tilde{f}_t}, \quad \frac{\partial E}{\partial W_{xi}} = x_t^T \frac{\partial E}{\partial \tilde{i}_t}, \quad \frac{\partial E}{\partial W_{xg}} = x_t^T \frac{\partial E}{\partial \tilde{g}_t}, \\ \frac{\partial E}{\partial W_{ho}} &= h_t^T \frac{\partial E}{\partial \tilde{o}_{t+1}}, \quad \frac{\partial E}{\partial W_{hf}} = h_t^T \frac{\partial E}{\partial \tilde{f}_{t+1}}, \quad \frac{\partial E}{\partial W_{hi}} = h_t^T \frac{\partial E}{\partial \tilde{i}_{t+1}}, \quad \frac{\partial E}{\partial W_{hg}} = h_t^T \frac{\partial E}{\partial \tilde{g}_{t+1}}, \quad \frac{\partial E}{\partial W_{yh}} = h_t^T \frac{\partial E}{\partial y_t} \end{aligned} \quad (16)$$

2.3 LSTM的船舶运动极短期预报建模流程

对于船舶运动时间序列 $\{x(t), t = 1, 2, \dots, N\}$, 对应输入向量为 $X(t-1)$, 构造训练样本集, 其中, $X(t-1) = [x(t-1), x(t-2), \dots, x(t-n)]^T$, 期望输出为 $x(t+L)$ ($L=1, 2, \dots$ 为预报步数)。采用反向传播法对 LSTM 网络结构各节点和参数求解, 其步骤如下:

- (1) 对各参数进行初始化, 前向计算每个神经元的输出值;
- (2) 反向计算每个神经元的误差项、误差函数 E 对神经元 j 的加权输入的偏导数;
- (3) 计算每个权重的梯度, 并对参数进行更新;
- (4) 重复步骤(2)、(3), 直到拟合回归模型误差满足精度要求, 利用该模型进行未来时刻预报。

3 实例预报与分析

为了验证预报模型的有效性, 本文采用某船耐波性模型试验数据进行建模预报, 试验工况如表2所示。

表2 试验工况
Tab.2 Test conditions

试验编号	有义波高 $H_{1/3}/\text{m}$	谱峰周期 T_p/s	浪向/ $^\circ$	航速 V/kn	测试参数
A1	4	10.6	180	6	纵摇、垂荡
A2			180	12	纵摇、垂荡
A3			135	6	横摇、纵摇、垂荡

利用小波滤波和LSTM相结合的预报模型对表2中不同工况下的运动进行预报,模型训练数据个数为500,预报时间为1~15 s,连续预报次数为500次,并对预报精度(E_{PA})进行统计分析。

$$E_{PA} = \sum_{t=N+1}^{N+n} \left\{ \left[\hat{x}(t) - \hat{x}_m(t) \right] \left[x(t) - x_m(t) \right] \right\} / (n-1) \sigma_{\hat{x}} \sigma_x \quad (17)$$

式中: E_{PA} 表示预报精度; n 为预报的数据个数; $x(t)$ 、 $\hat{x}(t)$ 分别为 t 时刻的真实值与预报值; $\hat{x}_m(t)$ 、 $x_m(t)$ 分别为 n 个预报值和实测值的平均期望; $\sigma_{\hat{x}}$ 、 σ_x 分别代表预报和期望的标准差。 E_{PA} 反映了预报曲线与真实曲线之间的形状相似程度。 E_{PA} 越接近1,表明预报曲线与实测数据曲线相似程度越高。

图6为浪向180°、航速6 kn工况下纵摇和垂荡运动预报精度随预报时间的关系,由图可以看出,随着预报时间的增长,预报精度逐渐下降。对于该工况下不同预报时间的纵摇运动预报精度要高于垂荡运动,纵摇运动预报时间为11 s时预报精度仍满足0.85以上,之后随着预报时间增长,下降速度明显加快。对于该工况下垂荡运动预报在预报精度大于0.85时,预报时间可达8 s。

图7为浪向180°、航速6 kn工况下纵摇运动超前4 s和8 s时的预报与试验结果对比,由图中可以看出,超前预报4 s时,预报结果与试验结果在相位及峰值上都吻合较好;超前预报8 s时,在峰(谷)值较大的时刻,无明显相位误差,预报结果与试验结果峰值误差变大。


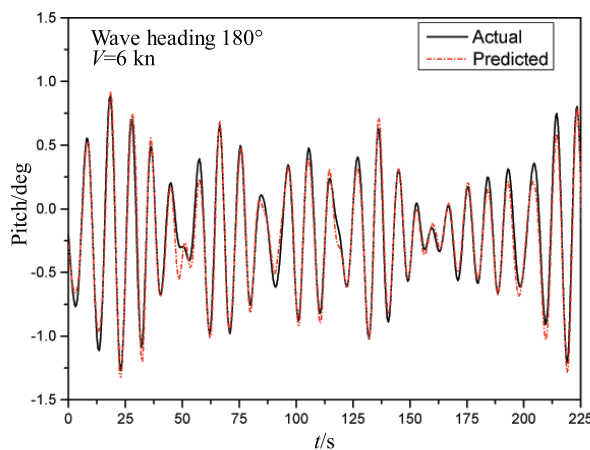
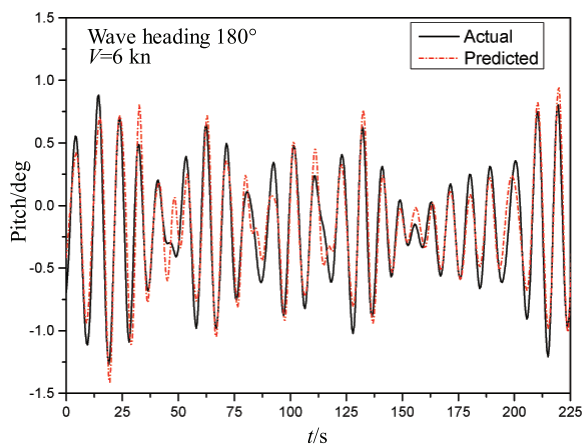


图6 纵摇、垂荡运动不同预报时间对应的预报精度 (浪向180°, $V=6$ kn)

Fig.6 Pitch and heave prediction precision versus prediction time (wave direction:180°, $V=6$ kn)



(a) 4 s 预报



(b) 8 s 预报

图7 纵摇运动预报结果(浪向180°, $V=6$ kn)

Fig.7 Pitch motion prediction (wave direction:180°, $V=6$ kn)

进一步对浪向180°、航速12 kn工况下纵摇和垂荡运动,浪向135°、航速6 kn工况下的横摇、纵摇和垂荡运动开展了极短期预报研究。图8和图9分别为两个工况下不同运动预报精度随预报时间的变化曲线。结果表明,随着预报时间的增加,纵摇运动预报精度均高于横摇和垂荡运动的预报精度。浪向180°、航速12 kn工况下,在满足预报精度 E_{PA} 大于0.85时,纵摇运动预报时间可达11 s,垂荡运动预报时间可达9 s;浪向135°、航速6 kn工况下,预报精度 E_{PA} 大于0.85时,横摇运动预报时间可达8 s,纵摇运动预报时间可达14 s,垂荡运动预报时间可达11 s。


图8 纵摇、垂荡运动预报精度(浪向180°, $V=12$ kn)

Fig.8 Pitch and heave prediction precision vs. prediction time (wave direction:180°, $V=12$ kn)


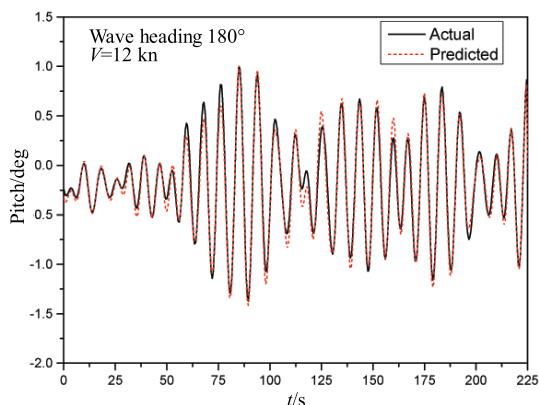

图9 横摇、纵摇和垂荡运动预报精度(浪向135°, $V=6$ kn)

Fig.9 Roll, pitch and heave prediction precision vs. prediction time (wave direction:135°, $V=6$ kn)

图10~14分别为浪向180°、航速12 kn工况下纵摇和垂荡运动,浪向135°、航速6 kn工况下的横摇、纵摇及垂荡运动超前4 s和8 s时的预报结果与试验结果对比。结果表明,超前预报4 s时,两个工况下运动预报结果与试验结果具有较好的相似度,且相位与峰值无明显差别;超前预报8 s时,预报结果峰值与试验结果峰值误差变大,但相位均吻合较好。




(a) 超前4 s预报




(b) 超前8 s预报

图10 纵摇运动预报结果(浪向180°, $V=12$ kn)

Fig.10 Pitch motion prediction (wave direction:180°, $V=12$ kn)



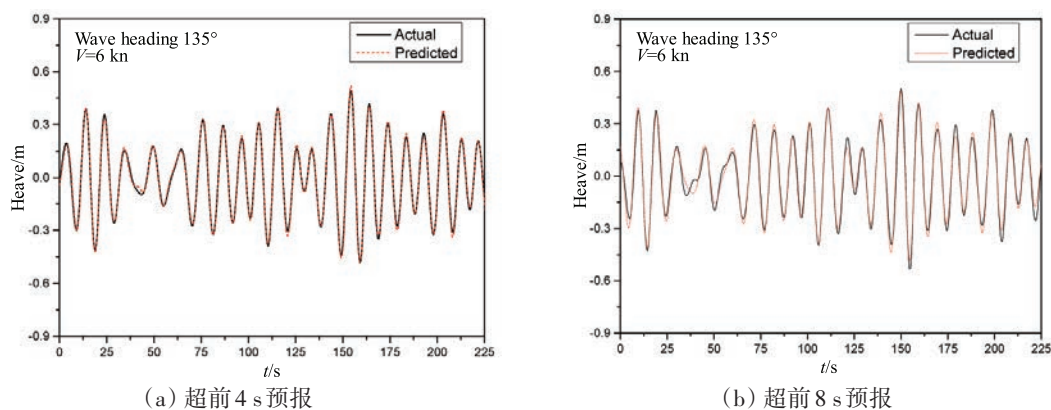
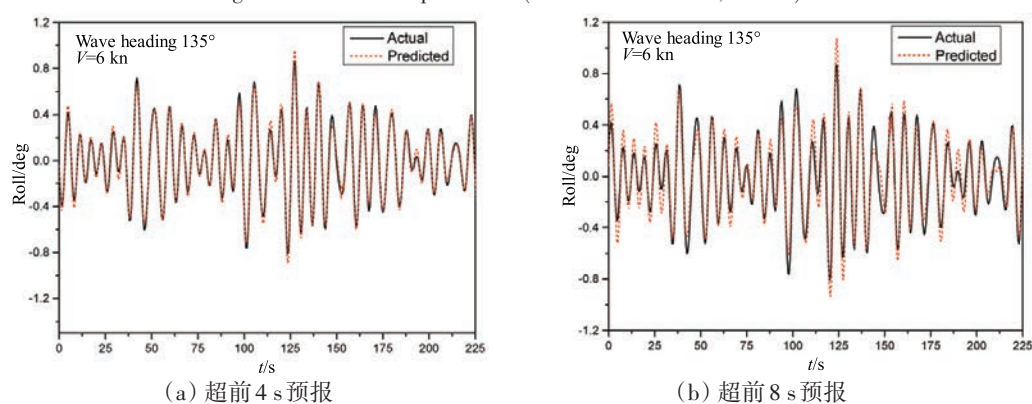
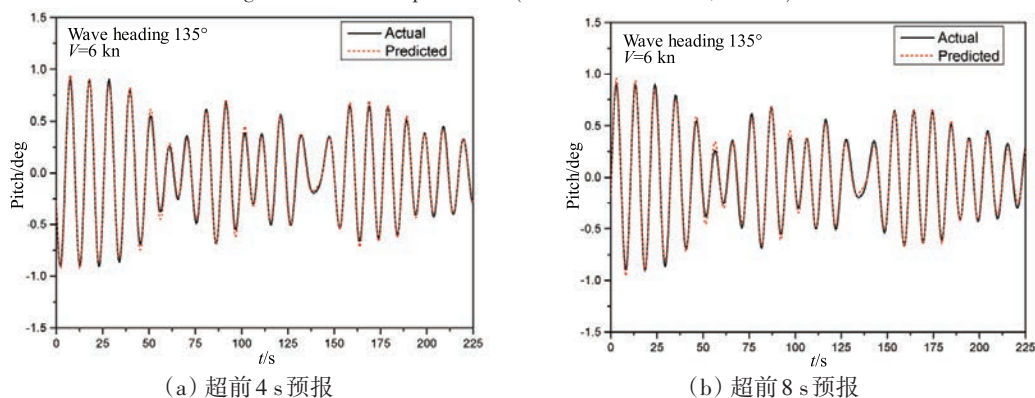
(a) 超前4 s预报



(b) 超前8 s预报

图11 垂荡运动预报结果(浪向180°, $V=12$ kn)

Fig.11 Heave motion prediction (wave direction:180°, $V=12$ kn)

图12 垂荡运动预报结果(浪向135°, $V=6$ kn)Fig.12 Heave motion prediction (wave direction:135°, $V=6$ kn)图13 横摇运动预报结果(浪向135°, $V=6$ kn)Fig.13 Roll motion prediction (wave direction:135°, $V=6$ kn)图14 纵摇运动预报结果(浪向135°, $V=6$ kn)Fig.14 Pitch motion prediction (wave direction:135°, $V=6$ kn)

4 结 论

本文针对船舶运动的非线性特性及测量噪声对预报精度的影响,建立了基于小波多分辨率分析的滤波方法,有效实现了船舶运动的滤波,并建立了基于LSTM神经网络的多步直接映射船舶运动极短期预报模型,通过耐波性试验数据对滤波方法和预报模型性能进行了验证分析,得到了如下主要结论:

(1)通过对小波滤波算法中小波基、阈值处理以及尺度函数的分析,确定了db N ($N=3\sim8$)系列、

sym $N(N=3\sim 8)$ 系列小波基函数、分解层数5层和1~4层细节信号硬阈值处理方法,可有效去除船舶运动信号中的高频噪声,解决了传统FFT滤波方法对当前时刻数据处理引起的端点突变问题,可有效提高船舶运动极短期预报建模的鲁棒性;

(2)通过不同航速、不同浪向下的预报结果与试验数据的对比分析,验证了所建立的基于LSTM神经网络的预报模型可有效实现船舶运动历史信息与未来时刻的非线性映射,横摇、纵摇和垂荡运动预报幅值和相位均取得了令人满意的精度,纵摇运动预报时间可达10 s,横摇和垂荡运动可达8 s以上。

参 考 文 献:

- [1] Zhao X, Xu R, Kwan C. Ship-motion prediction: Algorithms and simulation results[C]. ICASSP 2004: 125-128.
- [2] Valens C. A really friendly guide to wavelet[M]. 1999: 19-23.
- [3] 党淑雯. 光纤陀螺的信号分析及滤波技术[D]. 上海: 上海交通大学, 2010: 61-74.
Dang shuwen. Research on signal processing and denoising technique of fiber optic gyroscope[D]. Shanghai: Shanghai Jiao Tong University, 2010: 61-74.
- [4] 赵希人, 彭秀艳, 等. 舰船运动极短期预报建模的研究现状[J]. 船舶工程, 2002(3): 4-8.
Zhao Xiren, Peng Xiuyan, et al. Study status quo of extremely short-time modeling and predicting of ship motion[J]. Ship Engineering, 2002(3): 4-8.
- [5] 彭秀艳, 赵希人, 高奇峰. 船舶姿态运动实时预报算法研究[J]. 系统仿真学报, 2007, 19(2): 267-271.
Peng Xiuyan, Zhao Xiren, Gao Qifeng. Research on real-time prediction algorithm of ship attitude motion[J]. Journal of System Simulation, 2007, 19(2): 267-271.
- [6] 彭秀艳, 赵希人, 等. 具有艏前波观测量的大型船舶姿态运动预报[J]. 船舶力学, 2003, 7(2): 39-44.
Peng Xiuyan, Zhao Xiren, et al. Extreme short prediction of big ship motion having wave survey[J]. Journal of Ship Mechanics, 2003, 7(2): 39-44.
- [7] Yang Xilin, Pota H, Garratt M, et al. Ship motion prediction for maritime flight operations[C]. Proceedings of the International Federation of Automatic Control, Seoul, Korea, 2008.
- [8] Yang Xilin, Pota H, Garratt M, Ugrinovskii V. Prediction of vertical motions for landing operations of UAVs[C]. Proceedings of the 47th IEEE Conference on Decision and Control Cancun, Mexico, 2008.
- [9] 翁震平, 顾民, 刘长德. 基于二阶自适应Volterra级数的船舶运动极短期预报研究[J]. 船舶力学, 2010, 14(7): 732-740.
Weng Zhenping, Gu Min, Liu Changde. Extreme short-term prediction of ship motion based on second-order adaptive Volterra series[J]. Journal of Ship Mechanics, 2010, 14(7): 732-740.
- [10] Khan A, Bil C, Marion K, et al. Real time prediction of ship motions and attitudes using advantage prediction techniques[C]. 24th International Congress of the Aeronautical Sciences, 2004.
- [11] Khan A, Bil C, Marion K E. Theory and application of artificial neural networks for the real time prediction of ship motion [C]. 9th International Conference on Knowledge-based Intelligent Information and Engineering Systems, 2005.
- [12] 顾民, 刘长德. 基于混沌理论与RBF神经网络的船舶运动极短期预报研究[J]. 船舶力学, 2013, 17(10): 1147-1152.
Gu Min, Liu Changde. Extreme short-term prediction of ship motion based on chaotic theory and RBF neural network[J]. Journal of Ship Mechanics, 2013, 17(10): 1147-1152.
- [13] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural network[J]. Advances in Neural Information Processing System, 2014, 4: 3104-3112.
- [14] Zhang C, Tian Y. Automatic video description generation via LSTM with joint two-stream encoding[C]. International Conference on Pattern Recognition, IEEE, 2017.
- [15] Son H H. Toward a proposed framework for mood recognition using LSTM recurrent neuron network[J]. Procedia Computer Science, 2017, 109: 1028-1034.