

基于深度学习的海洋平台运动极短期预报

郭孝先, 卢文月, 李欣, 田新亮

- 1 上海交通大学船舶海洋与建筑工程学院, 上海 200240
2. 上海交通大学三亚崖州湾深海科技研究院, 三亚 572000

摘 要: 随着海洋工程逐渐向深远海迈进, 当水深大于 500 米后, 浮式平台被广泛的使用。在风浪流等环境条件的共同作用下, 浮式海洋平台始终在六自由度方向上进行摇荡运动。这种摇荡运动对海上作业安全构成了严峻的挑战。准确的运动极短期预报, 可以作为输入条件, 提高运动补偿装置的性能; 另一方面也可以提供及时的实时预警信息, 指导安全作业。深度学习方法, 从数据出发, 为平台运动的实时预报提供了新的思路。通过对一型典型的半潜油气生产平台的模型试验数据进行学习, 建立了基于长短期记忆神经网络 (LSTM) 的深度学习模型, 实现了对平台未来 20-40 秒内的垂荡和纵荡运动的精确预报, 预报精度达到 90% 以上。进一步地, 对输入窗口和输出窗口长度开展了敏感性研究, 给出了推荐的深度神经网络模型构型。

关键词: 浮式半潜平台; 极短期预报; 深度学习; LSTM

Predicting motions of an offshore platform based on a deep learning model

GUO Xiaoxian, LU Wen Yue, LI Xin, TIAN Xinliang

- 1 The School of Naval Architecture, Ocean & Civil Engineering (NAOCE),
Shanghai Jiao Tong University (SJTU), Shanghai 200240
- 2 SJTU Yazhou Bay Institute of Deepsea Technology, Sanya 572000

Abstract: Real-time motion prediction of a vessel or a floating platform can help to improve the performance of motion compensation systems. It can also provide useful early-warning information for offshore operations that are critical with regard to motion. In this study, a long short-term memory (LSTM)-based machine learning model was developed to predict heave and surge motions of a semi-submersible. The training and test data came from a model test carried out in the deep-water ocean basin, at Shanghai Jiao Tong University, China. The motion and measured waves were fed into LSTM cells and then went through several fully connected (FC) layers to obtain the prediction. With the help of measured waves, the prediction extended 46.5 s into future with an average accuracy close to 90%.

Key words: Semi-submersible platform; Real-time prediction; Deep learning; LSTM

0 引 言

随着海洋工程逐渐向深远海迈进, 当水深大于 500 米后, 浮式平台被广泛的使用。在风浪流环境激励的共同作用下, 浮式海洋平台始终在六自由度方向上进行摇荡运动。这种六自由度的摇荡运动对海上作业安全构成了严峻的挑战。平台运动极短期预报指实时地预报平台超前 10 - 50 秒 (一到几个波浪周期) 内的运动。准确的运动预报, 可以作为输入条件, 提高运动补偿装置的性能; 另一方面也可以提供及时的实时预警信息, 指导安全作业^[1]。

海洋平台在波浪中的运动已经被充分地认识和了解, 其六自由度的运动可以分为两类^[2]: 1)

横摇、纵摇和垂荡运动，由于存在自由液面提供的静水回复力，其固有周期均较短（接近波浪周期），以波浪激励下的波频运动为主；2）纵荡、横荡和首摇运动，运动回复力由系泊系统提供，其固有周期一般较大，此时除了波频运动外，还往往伴随着慢漂运动，其运动的成分更为复杂。从传统的水动力学观点出发，我们很少直接关心平台运动的具体时例，更多的是对平台在波浪激励下的统计学特征进行预报和分析，并以此指导工程实践活动^[3]。通常而言，研究特定的环境条件组合下的平台运动情况，入射波浪一般认为是一个平稳随机过程，保持随机性的前提下，同时具有一定的频域特征（如 JONSWAP 谱）。然后，通过建立对应的物理或试验模型，得到在入射环境激励下的响应时域特征，如最大值、平均值、有义值，以及其频域响应特征如频域传递函数或响应特征函数。对于这样的传统方法而言，对平台时例数据的预报是十分困难的，我们难以实时地将船舶及海洋环境条件作为输入，通过复杂的物理模型得到极短期的未来输出响应。

Triantafyllou 等^[4-5]应用 Kalman 滤波器最早进行了一艘驱逐舰在波浪作用下的运动极短期预报，其预报量达到 5s 左右。Kalman 滤波器的方法需要基于水动力学理论，建立船舶在波浪上运动的完整物理模型，其过程过于复杂，同时其预报准确性与所使用的物理模型直接相关。Yumori 等^[6]基于 ARMA（Auto-regressive moving average）模型，分析了船舶未来 2-4 秒内的运动。AR 模型已经可以脱离物理模型本身，而纯粹地从时例数据出发。Broome 等^[7]进一步地对比了不同的 AR 极短期预报模型，发现 AR 模型可以较好的处理平稳状态下的船舶运动预报问题，但是对突然产生的较大幅值响应往往无能为力。

机器学习方法，通过充分挖掘数据本身含有的丰富信息，为解决该问题提供了新途径。Sclavounos 等^[8]运用支持向量机（Support vector machine, SVM）进行了波面升高的极短期预报，其预报超前量达到了 5s 左右。Li 等^[9]同样运用浅层神经网络，实现了超前 2.5s 左右到波浪力预报，用于波浪能发电装置的控制输入。Khan 等^[10]进一步运用浅层神经网络，将船舶横摇运动的预报量提高到了 7s 左右。深度神经网络，其网络构型更加复杂，可以拟合更为复杂的函数映射。Ferrandis 等^[11]对比了不同的深度学习模型，认为 LSTM 模型最适合于船舶极短期预报问题。

本文通过对一型典型的半潜油气生产平台的模型试验数据进行学习，建立了基于长短期记忆神经网络（Long short term memory, LSTM）的深度学习模型，实现了对平台未来 20-40 秒内的垂荡和纵荡运动的精确预报，预报精度达到 90% 以上。进一步地，对输入窗口和输出窗口长度开展了敏感性研究，给出了推荐的深度神经网络模型构型。

1 研究方法对象

1.1 深度学习模型

机器学习是直接面向数据的方法，其算法简而言之可以归纳为：在输入向量 $\mathbf{x} \in \mathbb{R}^{r \times n}$ 和输出向量 $\mathbf{y} \in \mathbb{R}^m$ 之间，找到合适的非线性映射函数 \mathcal{F} ，使得

$$\mathcal{F}(\mathbf{x}; \mathbf{p}) \approx \mathbf{y} \quad (1)$$

其中， \mathbf{p} 为模型参数。在本文中，输入向量为平台的前一段时刻内的运动，输出向量为平台未来的运动。

相应地，损失函数定义为，

$$\mathcal{L} = \sum_{i=1}^N \frac{|\mathbf{y}_i - \mathcal{F}(\mathbf{x}; \mathbf{p})_i|^2}{N} \quad (2)$$

我们使用的所有数据均来源于海洋工程的常规风浪流试验的结果。将试验中采集到的波浪时例和运动时例作为输入向量，通过深度学习模型，给出平台未来一段时间内的运动时例。这里我们采用滑动窗口技术，即利用前一段时刻的运动及波浪升高作为输入（输入时间窗口），预报后一段时间的运动（输出时间窗口），然后保持窗口长度不变，并滚动向前。模型预报得到的结果将与平台运动的真实结果对比，从而计算得到损失函数。通过损失函数的最优化，更新模型的参数，

从而实现模型的训练。经过若干个周期迭代后，当损失函数不再下降，模型预报结果与真实结果足够相近，即认为完成了训练过程。此时的模型即为训练好的模型，可以用于在测试集进行平台运动的预报。需要指出的是，数据将在训练集上进行迭代更新，在测试集上进行预报应用，测试与训练数据无交叉。

循环神经网络（Recurrent neural networks, RNN）是用来专门处理时序问题的一类深度学习模型。如图 1(a)所示，RNN 的基本思路在于，将前一时刻的输出再与下一时刻的输入向量组合，重新输入进入模型，实现模型对前一时刻状态的“记忆”。这样以来，RNN 的输入向量长度理论上不受限制，每个时刻共享相同的神经元结构（可学习的参数），从而实现了对上一时间步状态的“记忆”，因此在时序问题上有着广泛的应用。然而在训练过程中，由于输出向量反复重新作为输入而经过激活函数的处理。这种“记忆”效应会随着传播次数的增多而逐渐减弱。同时，该模型容易出现梯度消失（gradient vanishing）的问题，造成 RNN 在实际应用过程中难以训练。RNN 提供了处理时序问题重要的思路，即将前一时刻的输出重新作为“记忆”效应输入，从而实现不同时刻的神经元共用相同的可训练参数（trainable parameters），实现对时间序列的有效处理。

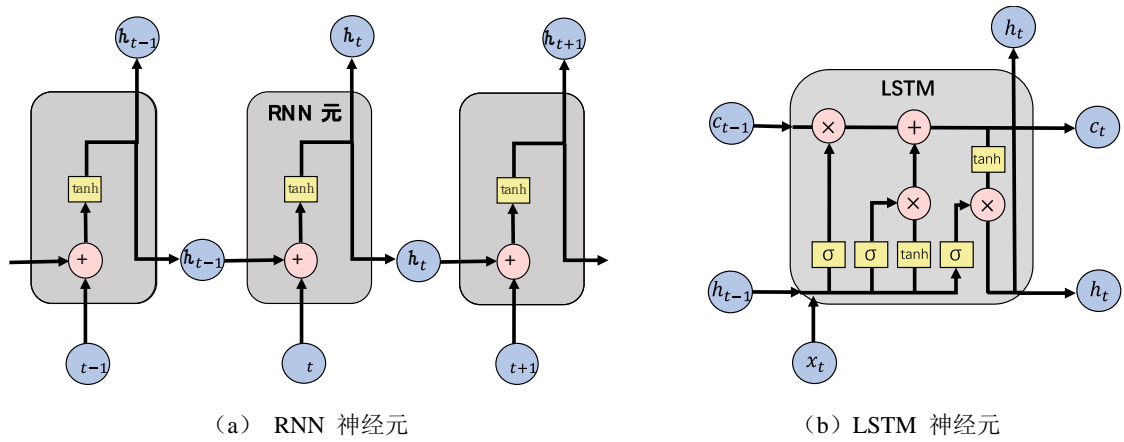


图 1 RNN 与 LSTM 神经元示意图

长短期记忆（Long short term memory, LSTM）神经网络^[12]是在 RNN 基础上的进一步变形发展。如图 1(b)所示，为了解决 RNN 训练中出现的梯度消失问题，同时实现“记忆”在不同神经元之间的高效传播。LSTM 增加了多个可学习的“门”函数，通过这些门由网络自主决定哪些“记忆”予以保留，那些“记忆”予以抛弃。LSTM 分别设计了输入门、遗忘门、状态门和输出门（见公式（3）至（8））。LSTM 已在交通流量预报、股市预测以及翻译等时序问题的上取得了巨大的进展，本文也以 LSTM 网络为基础，开展海洋平台运动时间序列的处理与预测。

$$i_t = \sigma(W_{ii}x_t + b_{ii} + W_{hi}h_{t-1} + b_{hi}) \quad (3)$$

$$f_t = \sigma(W_{if}x_t + b_{if} + W_{hf}h_{t-1} + b_{hf}) \quad (4)$$

$$g_t = \tanh(W_{ig}x_t + b_{ig} + W_{hg}h_{t-1} + b_{hg}) \quad (5)$$

$$o_t = \sigma(W_{io}x_t + b_{io} + W_{ho}h_{t-1} + b_{ho}) \quad (6)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t \quad (7)$$

$$h_t = o_t \odot \tanh(c_t) \quad (8)$$

其中， W 和 b 是网络需要学习的参数矩阵， σ 为激活函数， \odot 代表点乘，即两个向量之间进行对应元素的乘法计算。

本文采用的预报海洋结构物运动的模型的基本构型如图 2 所示。输入向量包含运动时例和波浪时例两个维度，这里的波浪时例指与平台平行位置布置的浪高仪获取的时例。平台的运动主要是由波浪诱导的，如果我们可以同时获知波浪的情况，将非常有利于进行平台运动的预报，这一点将在后文中详细体现。然后，输入向量直接进入 LSTM 层，由于 LSTM 层的神经元“无限复制”的性质，输入向量的长度可以自由决定。每个 LSTM 神经元输出一个固定长度的向量，我们使用

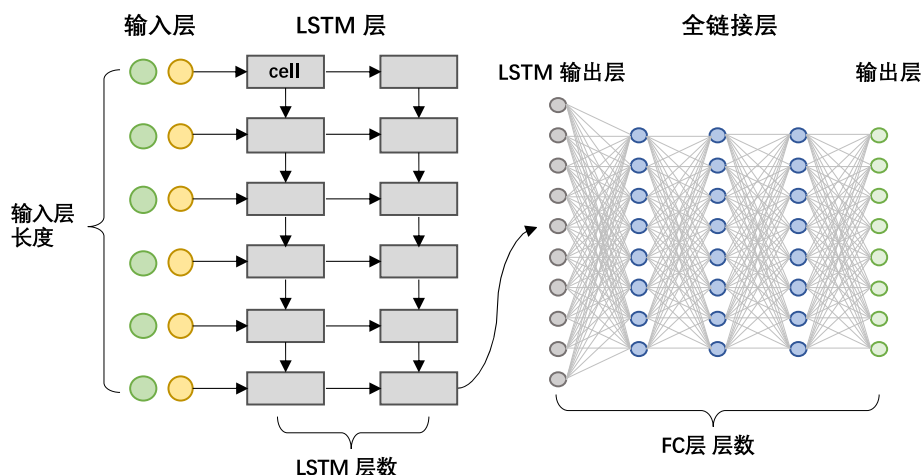


图2 用于平台运动预报的深度学习模型基本构型

最后一个 LSTM 神经元的输出向量作为全链接层（Fully connected layer, FC layer）的输入，经过若干全链接层后，最终我们得到输出向量。这里，输出向量的长度由我们要预报的时例长度所决定。以上，就是本文使用的 LSTM 型神经网络的基本构型，后文中我们还会对 LSTM 的层数，输出向量长度，FC 层的层数，隐藏层神经元数进行敏感性分析，最终得到推荐的用于平台运动预报的深度学习模型推荐构型。

1.2 研究对象

本文采用的研究对象是一型典型的半潜油气生产平台，其主要参数如表 1 所示。该型平台的吃水为 37m，边长 91.5m，排水量超过 10 万吨。

表 1 半潜平台主要参数

参数	单位	实型值	模型值
吃水	m	37.0	0.617
型宽	m	91.5	1.525
立柱中心距	m	70.5	1.175
排水量	MT	105000	474.2 Kg
重心高	m	32.0	0.533
横摇惯性半径	m	39.0	0.65
纵摇惯性半径	m	41.0	0.683
首摇惯性半径	m	42.0	0.7

模型试验在上海交通大学海洋深水试验池开展，模型试验缩尺比为 1:60。上海交通大学海洋深水试验池是世界上最先进的深水方水池之一，其长度为 50m，宽度为 40m，配备的大面积可升降假底使得工作深度在 0-10m 的范围内可调。如图 3 所示，在水池 L 型的两边上配备了多功能摇板造波机，该型造波机拥有 222 个独立的造波单元，可以生成多方向的三维波浪。水池的另两边配备大范围的被动式消波滩，可以有效地消除反射波浪的影响。水池还配备了无接触光学运动测量系统，电容式单点波浪测量系统等先进的试验仪器，满足海洋工程试验的要求。

本试验对半潜平台 6 个自由度的运动进行了测量，采用无接触式的光学测量系统，测量精度优于 1mm；采用电容式浪高仪，对波浪场进行了测量，测点位于与模型平行的位置（见图 3），并与模型保持了一定的距离，避免平台辐射波浪的干扰，测量精度优于 0.1cm。




图3 试验布置示意图

本试验的平台模型主体为木质并在外层敷设玻璃钢以防水，在试验下水前对模型的重量、重心及惯量进行调整，以满足质量相似的要求。模型在四角分别链接四根系泊缆，这里我们采用了等效系泊的方式，在保持平台在水平方向上的刚度特性一致的前提下，将平台在每个方向上的3根系泊缆合并为了一根。试验中，输入不规则波浪由 JONSWAP 谱模拟（参见公式(9)），本文涉及的海况主要由百年一遇和千年一遇组成，每组谱峰周期和有义波高的组合下，分别涉及8个不同的波浪组合，详细参数见表2。

$$S(\omega) = \alpha H_s^2 \frac{\omega^{-5}}{\omega_p^{-4}} \exp\left[-1.25 \left(\frac{\omega}{\omega_p}\right)^{-4} \gamma \exp\left(\frac{(\omega - \omega_p)^2}{2\tau^2 \omega_p^2}\right)\right] \quad \# \quad (9)$$

其中， H_s 为有义波高， T_p 为谱峰周期， γ 为谱型参数（这里取3.3）。

表2 波浪环境条件表

编号	描述	H_s	T_p	所属训练集
WC 1	百年一遇，短周期	13.4	14.2	训练集
WC 2	百年一遇，种子 1	13.4	14.7	测试集
WC 3	百年一遇，种子 2-重复	13.4	14.7	训练集
WC 4	百年一遇，长周期	13.4	15.7	训练集
WC 5	千年一遇，短周期	16.9	14.4	训练集
WC 6	千年一遇，种子 1	16.9	15.9	训练集
WC 7	千年一遇，种子 2-重复	16.9	15.9	训练集
WC 8	千年一遇，长周期	16.9	16.9	训练集

对于每个海况，试验时长为30分钟，对应实际海况3小时，同时对波浪和平台运动进行测量，测量频率为10Hz。由于本文主要的目的为利用实验数据，进行相关对运动时序的预测分析，试验设置本身并不是本文的重点，这里因为文章篇幅的限制不再详细描述。有关海洋工程模型试验的详细过程可以参考文献[13]。

1.3 训练与测试数据库

深度学习的核心在于数据库的获取与建立，数据库的质量直接关系到预报模型的优劣。如前文所述，本文将利用平台的运动信息结合波浪时例进行平台运动的实时预报，针对一型 10 万吨级别的半潜油气生产平台开展，训练数据由 1:60 的海洋工程水池模型试验提供。

首先，图 4-6 分别给出了波浪、垂荡和纵荡运动的时例及其对应的谱分析结果。可以看出，实验生成的波浪与目标值在谱分析结果上符合的很好，满足要求。波浪能量集中在 0.5 rad/s 左右，呈现出典型的窄带宽谱的频域和时域特征。平台的垂荡运动则与波浪时例基本对应，呈现出明显的波频运动特性，能量集中于波频位置，虽然在固有频率位置也有一个峰值，但相较于波频主峰值而言，并不突出。平台的纵荡运动不仅包含波频成分，还存在大范围的低频运动，也就是熟知的低频慢漂运动，这一特征同时也反应在谱分析结果上，在 0.048 rad/s 的低频位置存在一个明显的峰值。




图 4 波浪时例及其谱分析 (WC3, Hs: 13.4m, Tp: 14.7s)




图 5 垂荡运动时例及其谱分析 (WC3, Hs: 13.4m, Tp: 14.7s)




图 6 纵荡运动时例及其谱分析 (WC3, Hs: 13.4m, Tp: 14.7s)

对于我们记录到的运动时例 $\{x(t_i), i \in N\}$ 和波浪时例 $\{w(t_i), i \in N\}$ ，我们为了使得模型输入归一化，首先对输入数据进行正则化处理，

$$\tilde{x}(t_i) = \frac{x(t_i) - A}{B} \quad \# \quad (10)$$

其中, A 和 B 为正则化参数, 我们分别取为波浪、纵荡和垂荡运动全部数据对应的均值和方差。

然后, 输入、输出向量按下式组成,

$$\mathbf{X}_p^{n \times 2} = [\tilde{x}(t_{p-n}), \tilde{x}(t_{p-n+1}), \dots, \tilde{x}(t_{p-1})]^T + [\tilde{w}(t_{p-n+w}), \tilde{w}(t_{p-n+w+1}), \dots, \tilde{w}(t_{p+w-1})]^T \quad (11)$$

$$\mathbf{Y}_p^{m \times 1} = [\tilde{x}(t_p), \tilde{x}(t_{p+1}), \dots, \tilde{x}(t_{p+m-1})]^T \quad (12)$$

其中, 参见图 7, t_p 代表当前时刻, 输入向量长度为 n , 取 t_{p-n} 到 t_{p-1} 长度运动时例和 t_{p-n+w} 到 t_{p+w-1} 时刻的波浪作为输入向量, 输出向量长度为 m , 输出运动时例从 t_p 到 t_{p+m-1} 。

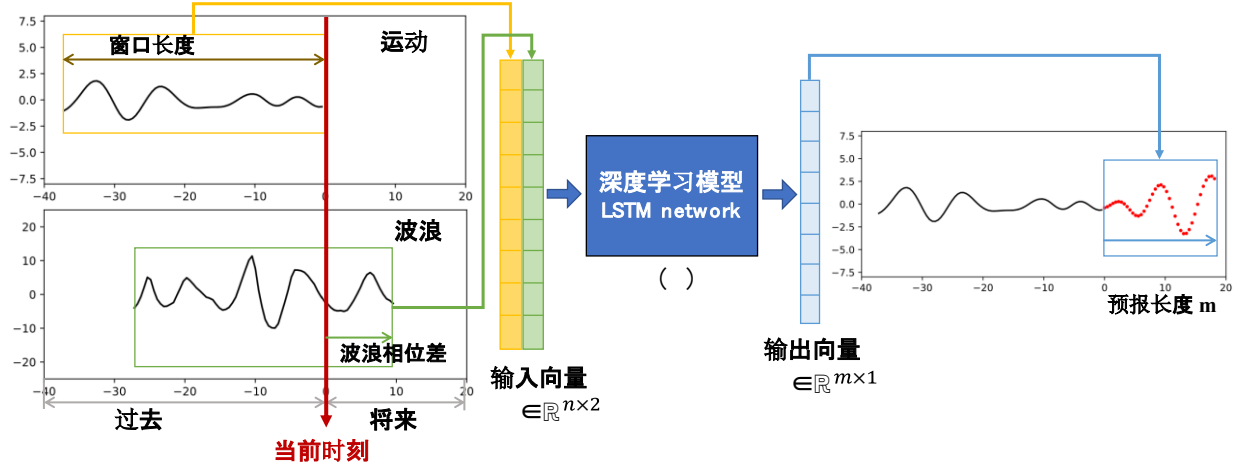


图 7 输入、输出向量构成示意图

这里, 需要特别说明一下波浪与运动的相位差 w 的定义和意义。如图 3 所示, 波浪时例的采集位置在与平台中心平行的位置上, 由于入射波浪为长峰波, 采集到的波浪升高的与平台中心位置所经历的波浪升高是同相位的。我们知道, 平台的运动是波浪引起的, 如果可以“预知”未来时刻的波浪, 有利于作出更准确的运动预报。波浪是从平台前方传播过来的, 在平台来浪方向的前侧测量波浪即可预知“未来”平台中心位置的波浪升高。因此, 我们通过调整采集波浪时例与运动采集时例之间的时间差 w , 达到前方测量波浪的目的。

通过以上方法, 我们利用试验得到的 30 分钟长度的运动与波浪的时间序列数据, $\{x(t_i), i \in N\}$ 和 $\{w(t_i), i \in N\}$, 组成了深度学习所需的数据库 (输入-输出向量对)。转化为实型值后, 采样频率为 1.29Hz (时间步长为 0.775s), 对于每一个 30 分钟长度的时例数据, 约转换为 15000 个输入-输出向量对。我们将其中的 WC 1 和 WC 3-8 作为训练数据集, WC 2 作为测试集, 用于深度学习模型的训练。

1.4 模型训练过程

以图 2 的基本模型构型为基础, 具体的模型参数见表 3, 共 19470 个可学习的参数。在训练中, 采用 Adam 算法用于损失函数的优化, 学习率在最初的 20 个周期 (epoch) 内保持 0.01, 然后每 100 个周期下降为之前学习率的 0.1。同时, 应用 Mini-batch 方法用于学习参数的梯度下降, 批大小 (batch size) 为 512。在训练过程中, 训练和测试集上的损失函数值随训练周期下降的曲线如图 8 所示。可以看出, 在约 200 个周期后, 损失函数基本下降到一个可以接受的区间, 并且不再继续下降。在实际训练过程中, 训练共 300 个周期后, 认为模型达到了预期效果并停止训练。

表 3 深度学习模型参数表

编号	层	数据构型
1	输入层	(256, n, 2)
2	LSTM 层	(256, n, 50, 1)
3	FC 层 - 1	(256, 50, 1)
4	FC 层 - 2	(256, 50, 1)
5	FC 层 - 3	(256, 50, 1)
6	输出层	(256, m, 1)




图 8 训练过程损失函数下降曲线

2 结果分析与讨论

图 9 与 10 给出了采用深度学习模型,在测试数据集上进行的平台运动预报结果。作为出发点,使用 60 个时间步作为预报的窗口,向前预报 20 个时间步,同时波浪与运动的相位差选择为 20 个时间步,也就是说向前预知 20 个时间步的波浪数据。

为量化评价预报的效果,定义预报的准确率通过下式得到,

$$\text{Acc} = 1 - \left| 1 - \frac{\text{Area}(\mathcal{F}(X_p) - \text{Mean}(\mathcal{F}(X_p)))}{\text{Area}(Y_p - \text{Mean}(Y_p))} \right| \# \quad (13)$$

其中, $\text{Area}(\cdot)$ 表示计算该段曲线与 X 轴围成的面积, $\text{Mean}(\cdot)$ 为该段曲线的平均值。

如图 10 和 11 所示,本文使用的模型取得了良好的预报结果,对于垂荡运动,其预报准确率达到了 90%,对于纵荡运动则为 80% 左右。所示的结果证明了本文推荐的深度学习模型可以较为准确地用于平台运动的预报。总体来说,垂荡运动的预报效果要好于纵荡运动,这是因为纵荡运动除了波频成分外,还有明显的低频成分,在预报时会更为困难。

图 11 和 12 给出了在不同时间窗口和波浪相位下的预报准确率。首先,时间窗口 (n) 指的是在当前时刻回溯的 n 个时间步。我们这里采用了滑动窗口的方法实现预报的滚动向前,使用当前时刻向前的 n 个时间步的数据来向后预报 m 个时间步的运动。那么,首先要解决的问题就是滑动窗口长度与预报长度之间的关系。如图 12 所示,当窗口长度过短时,预报的准确率较低,这是因为没有足够的信息进入模型,相关模型无法建立输入-输出之间的准确关系。随着输入窗口长度的增加,预报精度随之增加;但当 $n \geq 3m$ 后,预报的精度不再增加了。可以认为,当前时刻的运动主要与之前三倍时长内的运动相关,但是与再早先的运动数据没有紧密的联系。

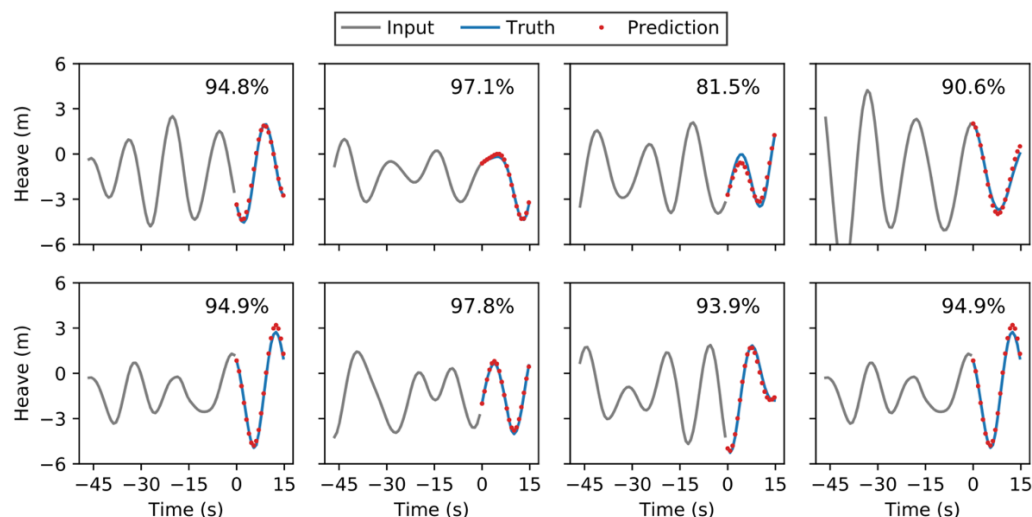


图9 平台垂荡运动预报在测试集上的结果

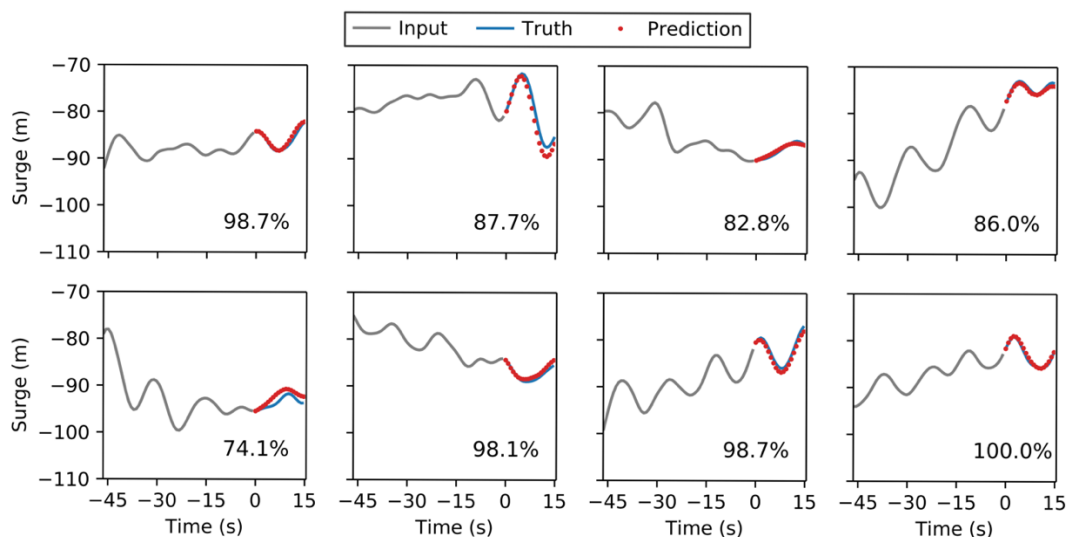


图10 平台纵荡运动预报在测试集上的结果

图12给出的是波浪的相位差与运动预报准确率之间的关系。首先，在试验中，波浪的时例采集是在平台平行位置上进行的，也就是与平台中心位置此时的波浪升高时例是相同相位的。事实上，波浪是从前方传播过来的，换言之，我们如果在平台的前方进行测量，则可以“预知”之后时刻平台中心位置所经历的波浪。我们通过相对于平台的运动，向前移动波浪的运动时例（即增加 w ），则可以数值上实现与波浪在平台前方的测量相同的效果。通过改变 w ，改变了波浪时例与运动时例之间的相对时间差。图12中可以看出，当 $w < m$ 时，预报精度较差，这是因为预知的“未来”波浪信息较少，模型很难给出准确的运动预报结果；当 $w = m$ 时，预报精度最好；当 $w > m$ 后，预报精度逐渐降低，这是因为最关键的波浪信息被移动到了模型中较为靠前的位置，这些波浪信息需要额外的在LSTM层的神经元中传播，一些信息在传播过程中被“遗弃”了，造成了预报准确性的降低。

我们保持 $n = 3m$ 以及 $w = m$ 这两个关系，通过预报窗口的拓展，实现预报时序长度的增加。图13给出了相关的结果，这里我们分别对纵荡和垂荡运动，将预报的时长从20个时间步，拓展到了60个时间步。我们相信，按照这个比例，还可以进一步拓展预报的时长。

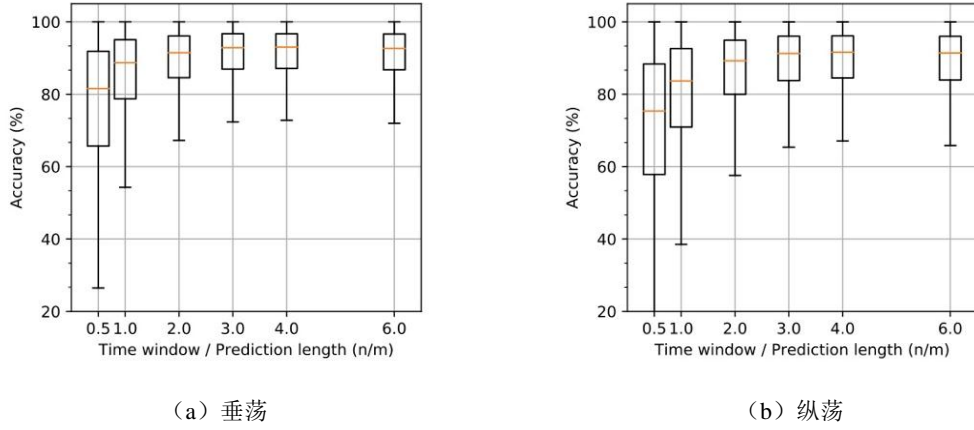


图 11 不同时间窗口 (n) 情况下的预报准确率




图 12 不同波浪相位 (w) 下的预报准确率

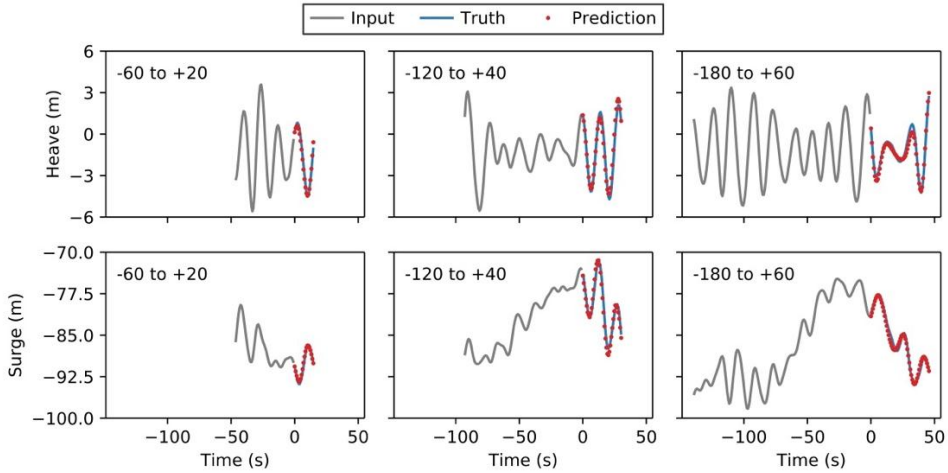


图 13 不同时间窗口下的对平台垂荡和纵荡运动的预报结果

3 结 论

本文通过对一型典型的半潜油气生产平台的模型试验数据进行学习，建立了基于长短期记忆神经网络 (LSTM) 的深度学习模型，实现了对平台未来 20-40 秒内的垂荡和纵荡运动的精确预报，预报精度达到 90% 以上。进一步地，对输入窗口和输出窗口长度开展了敏感性研究，给出了 $n = 3m$

以及 $w = m$ 这样的推荐深度神经网络模型构型。

参考文献:

- [1] Liu, Y., Duan, W., Huang, L., et al. The input vector space optimization for LSTM deep learning model in real-time prediction of ship motions[J]. Ocean Engineering, 2020, 213, 107681.
- [2] Faltinsen. 船舶与海洋工程环境载荷[M]. 上海交通大学出版社, 2008.
- [3] Michel K Ochi. Applied probability and stochastic processes: in engineering and physical sciences / Michael K. Ochi[M]. Wiley, 1990.
- [4] Triantafyllou M S, Athans M, Massachusetts Institute of Technology. Laboratory for Information and Decision Systems. Real time estimation of the heaving and pitching motions of a ship using a Kalman filter[C]// OCEANS 81. IEEE, 2010.
- [5] Triantafyllou M, Bodson M, Athans M. Real time estimation of ship motions using Kalman filtering techniques[J]. 1983, 8(1):9-20.
- [6] Yumori I. Real Time Prediction of Ship Response to Ocean Waves Using Time Series Analysis[C]// Oceans. IEEE, 1981.
- [7] Broome D R, Pittaras A. The Time Prediction of Ship Motions at Sea[J].
- [8] Slavounos P D, Ma Y. Artificial Intelligence Machine Learning in Marine Hydrodynamics[C]// ASME 2018 37th International Conference on Ocean, Offshore and Arctic Engineering. 2018.
- [9] Li L, Gao Z, Yuan Z M. On the sensitivity and uncertainty of wave energy conversion with an artificial neural-network-based controller[J]. Ocean Engineering, 2019, 183(JUL.1):282-293.
- [10] Khan A, Bil C, Marion K E. Ship Motion Prediction For Launch And Recovery Of Air Vehicles[J]. Oceans Proceedings of Mts/ieee, 2005:2795 - 2801 Vol. 3.
- [11] Ferrandis, Jose del guila, Triantafyllou M, Chrysostomidis C, et al. Learning functionals via LSTM neural networks for predicting vessel dynamics in extreme sea states[J]. ArXiv, 2019, 1912.13382.
- [12] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735-1780.
- [13] Li D, Lu W, Li X, et al. Second-order resonant motions of a deep-draft semi-submersible under extreme irregular wave excitation[J]. Ocean Engineering, 2020, 209:107496.

作者简介:

郭孝先, 男, 1991 年生, 上海交通大学船舶海洋与建筑工程学院, 助理研究员。研究方向: 深度学习在海洋工程水动力学上应用的研究

卢文月, 男, 1988 年生, 上海交通大学船舶海洋与建筑工程学院, 助理研究员

李欣, 女, 1975 年生, 上海交通大学船舶海洋与建筑工程学院, 教授

田新亮, 男, 1986 年生, 上海交通大学船舶海洋与建筑工程学院, 副教授

通讯地址: 上海市闵行区东川路 800 号上海交通大学木兰楼 B803 室 邮编: 200240

电话: 18801965268 Email: xiaoxguo@sjtu.edu.cn